Report

1 Q1

本报告使用的系统为 **AutoClaw**，是开源项目 OpenClaw 的智谱 AutoGLM 定制版。系统运行环境为 Windows 11 本地机器，通过 WebChat 界面与用户交互。

1.1 工作机理

系统采用 **"Gateway + LLM + 工具"** 的三层架构，核心工作流程如下：

1. **消息接入**：用户通过 WebChat、Telegram 等渠道发送消息，Gateway 网关接收消息后，将其连同系统提示词（System Prompt）一起组装成 LLM 请求。
2. **LLM 推理**：大语言模型根据指令决定回复方式——直接回答，或调用一个/多个工具（如执行 Shell 命令、搜索网页、操作浏览器等）。
3. **工具执行**：Gateway 的工具调度引擎执行 LLM 选定的工具，将执行结果返回给 LLM 进行下一步推理。这一过程可多次循环，直到 LLM 给出最终回答。
4. **Skill 插件扩展**：Skill 是可插拔的能力模块，每个 Skill 包含一份 `SKILL.md` 配置文件和配套脚本。当 Agent 识别到匹配的任务场景时，会自动加载对应的 Skill 并遵循其指令执行。例如，当用户需要深度调研时，`autoglm-deepresearch` Skill 会被激活，指导 Agent 进行定向搜索和页面深度阅读。
5. **持久化存储**：工作空间（Workspace）中的 `MEMORY.md`、`AGENTS.md`、`USER.md` 等文件实现跨会话的记忆与人格连续性，使 Agent 能在每次新会话中恢复上下文。

1.2 三个与数据分析相关的技能

1.2.1 Skill 1：autoglm-deepresearch（深度调研）

功能概述

对用户提出的课题进行深度研究和调研，输出结构化的深度报告。

工作方式：先进行 1–2 次定向网络搜索，再对 1–3 个关键页面进行深度阅读，过程中逐步展示中间发现，最终生成包含概述、现状分析、典型案例、发展趋势等章节的完整调研报告。

数据分析应用场景：在进行数据分析项目前，通常需要对研究背景、数据集来源、相关领域最新进展等进行前期调研。例如，在分析 BRFSS 糖尿病数据集前，可以用此

技能调研 BRFSS 问卷的设计背景、糖尿病分类标准及最新的流行病学数据，为后续的数据分析提供领域知识支撑。

1.2.2 Skill 2：autoglm-websearch（网络搜索）

功能概述

调用 AutoGLM Web Search API 进行网络信息搜索，获取实时资讯和公开数据。

工作方式：通过 Python 脚本调用搜索接口，返回结构化搜索结果（页面标题、URL、摘要），自动整理为自然语言回答并附带引用来源。

数据分析应用场景：数据分析过程中经常需要查询外部数据源、验证数据背景或查找最新统计报告。例如，搜索 “BRFSS 2015 diabetes survey methodology” 来了解数据采集方法，或搜索最新的糖尿病患病率统计数据作为分析结论的对比参照。此外，在遇到数据中的异常值或不确定的字段含义时，网络搜索也是快速定位问题的重要手段。

1.2.3 Skill 3：autoglm-stock-analysis（金融数据分析）

功能概述

对股票、证券、基金等金融资产进行多维度结构化分析，输出包含基本面、技术面和市场情绪的完整研究报告。

工作方式：组合使用三种数据获取方式——`websearch`（搜索财报新闻）、`open-link`（读取网页正文）和 `yfinance`（获取实时行情数据），三者协同进行信息采集与交叉验证，最终输出结构化的综合分析报告。

数据分析应用场景：这是最典型的数据分析技能之一，其分析流程与大数据分析的标准流程高度一致：

- **数据采集**：从多个数据源（搜索引擎、财经网页、行情 API）获取原始数据；
- **数据清洗与验证**：通过交叉验证确保数据准确性；
- **多维分析**：从基本面、技术面、市场情绪等多个维度进行综合分析；
- **结构化报告**：将分析结果整理为表格、评分和文字报告。

这种 “多源数据整合 → 交叉验证 → 多维分析 → 结构化输出” 的模式，与使用 Spark 对大规模数据集进行分析的思路完全一致。

1.3 Spark DataFrame 创建与数据分析

1.3.1 数据加载与 Schema

使用 PySpark 读取 CSV 文件，创建 Spark DataFrame。数据集包含 253,680 条记录，22 个字段。

Listing 1: Spark Session 创建与数据加载

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, count, mean, round

spark = SparkSession.builder \
    .appName("Diabetes_BRFSS2015_Analysis") \
    .master("local[*]") \
    .getOrCreate()

df = spark.read.csv("diabetes_012_health_indicators_BRFSS2015.csv",
                    header=True, inferSchema=True)
```

DataFrame Schema 如下所示：

```
root
 |-- Diabetes_012: double (nullable = true)
 |-- HighBP: double (nullable = true)
 |-- HighChol: double (nullable = true)
 |-- CholCheck: double (nullable = true)
 |-- BMI: double (nullable = true)
 |-- Smoker: double (nullable = true)
 |-- Stroke: double (nullable = true)
 |-- HeartDiseaseorAttack: double (nullable = true)
 |-- PhysActivity: double (nullable = true)
 |-- Fruits: double (nullable = true)
 |-- Veggies: double (nullable = true)
 |-- HvyAlcoholConsump: double (nullable = true)
 |-- AnyHealthcare: double (nullable = true)
 |-- NoDocbcCost: double (nullable = true)
 |-- GenHlth: double (nullable = true)
 |-- MentHlth: double (nullable = true)
 |-- PhysHlth: double (nullable = true)
 |-- DiffWalk: double (nullable = true)
 |-- Sex: double (nullable = true)
 |-- Age: double (nullable = true)
 |-- Education: double (nullable = true)
 |-- Income: double (nullable = true)
```

数据集总行数为 **253,680**，总列数为 **22**。

1.3.2 Diabetes_012 类别分布

目标变量 `Diabetes_012` 分为三类：

- `0.0`：无糖尿病
- `1.0`：糖尿病前期
- `2.0`：糖尿病

分别使用 Spark DataFrame API 和 Spark SQL API 统计类别分布，结果完全一致，如表1所示。

表 1: Diabetes_012 类别分布

Diabetes_012	类别	Count	Percentage
0.0	无糖尿病	213,703	84.24%
1.0	糖尿病前期	4,631	1.83%
2.0	糖尿病	35,346	13.93%
总计		**253,680**	**100%**

从分布可以看出，数据集存在明显的类别不平衡问题：无糖尿病样本占比超过 84%，而糖尿病前期样本仅占不到 2%。

1.3.3 描述性分析

对五个健康指标 `HighBP`（高血压）、`HighChol`（高胆固醇）、`BMI`（身体质量指数）、`PhysActivity`（体力活动）、`Age`（年龄）按糖尿病类别进行分组统计。

均值分析 表2展示了各指标按类别的均值，DataFrame API 与 Spark SQL API 结果一致。

表 2: 各健康指标按糖尿病类别的均值

Diabetes_012	HighBP	HighChol	BMI	PhysActivity	Age
0.0 (无糖尿病)	0.37	0.38	27.74	0.78	7.79
1.0 (糖尿病前期)	0.63	0.62	30.72	0.68	9.08
2.0 (糖尿病)	0.75	0.67	31.94	0.63	9.38

百分比分析 对于二值变量（HighBP、HighChol、PhysActivity），均值乘以 100 即为该特征的阳性比例，如表3所示。

表 3: 二值健康指标的阳性比例 (%)

Diabetes_012	HighBP (%)	HighChol (%)	PhysActivity (%)
0.0 (无糖尿病)	37.11%	37.92%	77.91%
1.0 (糖尿病前期)	62.90%	62.08%	67.85%
2.0 (糖尿病)	75.27%	67.01%	63.05%

BMI 详细统计 对 BMI 进行更详细的描述性统计，包括最小值、最大值和标准差，如表4所示。

表 4: BMI 按糖尿病类别的详细统计

Diabetes_012	均值	最小值	最大值	标准差	样本数
0.0 (无糖尿病)	27.74	12.0	98.0	6.26	213,703
1.0 (糖尿病前期)	30.72	13.0	96.0	6.96	4,631
2.0 (糖尿病)	31.94	13.0	98.0	7.36	35,346

1.3.4 风险因素分析

为比较各指标与糖尿病风险的相关性，将糖尿病组与非糖尿病组进行对比，如表5所示。

表 5: 风险因素对比（糖尿病组 vs 非糖尿病组）

指标	非糖尿病 (0)	糖尿病 (2)	差异
高血压比例 (HighBP)	37.11%	75.27%	**+38.16 p.p.**
高胆固醇比例 (HighChol)	37.92%	67.01%	**+29.09 p.p.**
BMI 均值	27.74	31.94	**+4.20**
体力活动比例 (PhysActivity)	77.91%	63.05%	**-14.86 p.p.**
年龄均值	7.79	9.38	+1.59

结论：与糖尿病风险最相关的因素 根据上述分析，按相关性从高到低排序：

1. **高血压 (HighBP)**：糖尿病组的高血压比例（75.27%）比非糖尿病组（37.11%）高出 38 个百分点，是差异最大的指标。

2. **高胆固醇 (HighChol)**：糖尿病组的高胆固醇比例（67.01%）比非糖尿病组（37.92%）高出 29 个百分点，差异显著。

3. **高 BMI**：糖尿病组的平均 BMI（31.94）处于肥胖范围，比非糖尿病组（27.74，超重范围）高出 4.2，BMI 与糖尿病风险呈明显正相关。

4. **缺乏体力活动 (PhysActivity)**：糖尿病组的体力活动比例（63.05%）明显低于非糖尿病组（77.91%），缺乏运动是重要的可干预风险因素。

5. **年龄 (Age)**：糖尿病组的平均年龄（9.38，对应约 65-69 岁）高于非糖尿病组（7.79，对应约 55-59 岁），年龄增长与糖尿病风险增加相关，但差异相对较小。

综上，**高血压、高胆固醇和高 BMI** 是与糖尿病风险最相关的三个因素，且均为可干预的代谢相关指标。

API 对比说明 本分析同时使用了 Spark DataFrame API 和 Spark SQL API 实现，两种方式输出的结果完全一致，验证了分析的准确性。DataFrame API 适合链式操作和动态编程，Spark SQL API 则更接近传统 SQL 语法，便于熟悉 SQL 的用户使用。本次分析选择两种方式并行实现，既保证了结果的正确性，也展示了 Spark 的灵活性。

1.4 数据观察与结论

基于上述分析，从该数据集中得出以下三个主要结论：

1.4.1 结论一：代谢综合征的聚集效应

观察结论 1

糖尿病患者同时患有高血压和高胆固醇的比例显著高于非糖尿病人群，提示代谢综合征各组分之间存在聚集效应。

分析代码：

Listing 2: 代谢综合征聚集效应分析

```
from pyspark.sql.functions import when, col

# 创建联合指标：同时患有高血压和高胆固醇
df_with_combo = df.withColumn(
    "both_BP_Chol",
    when((col("HighBP") == 1) & (col("HighChol") == 1), 1).otherwise
        (0)
)
```

```
# 按糖尿病类别统计
combo_stats = df_with_combo.groupBy("Diabetes_012") \
    .agg(
        round(mean("both_BP_Chol") * 100, 2).alias("both_BP_Chol_pct"
            ),
        round(mean("HighBP") * 100, 2).alias("HighBP_pct"),
        round(mean("HighChol") * 100, 2).alias("HighChol_pct")
    )
combo_stats.show()
```

分析结果：

表 6: 代谢指标聚集效应分析

Diabetes_012	类别	样本数	高血压比例	高胆固醇比例	两者共存比例
0.0	无糖尿病	213,703	37.11%	37.92%	20.32%
1.0	糖尿病前期	4,631	62.90%	62.08%	43.62%
2.0	糖尿病	35,346	75.27%	67.01%	54.36%

从表中可以看出，糖尿病组同时患有高血压和高胆固醇的比例（54.36%）是非糖尿病组（20.32%）的 **2.67 倍**，表明代谢异常具有明显的聚集效应。

1.4.2 结论二：BMI 与糖尿病风险的剂量-反应关系

观察结论 2

BMI 与糖尿病风险呈明显的剂量-反应关系：重度肥胖人群（BMI > 40）的糖尿病患病率（33.54%）是正常体重人群（5.70%）的 **5.88 倍**。

分析代码：

Listing 3: BMI 分层风险分析

```
# BMI 分组
df_with_bmi_cat = df.withColumn(
    "BMI_category",
    when(col("BMI") < 18.5, "偏瘦")
    .when((col("BMI") >= 18.5) & (col("BMI") < 25), "正常")
    .when((col("BMI") >= 25) & (col("BMI") < 30), "超重")
    .when((col("BMI") >= 30) & (col("BMI") < 35), "肥胖I级")
    .when((col("BMI") >= 35) & (col("BMI") < 40), "肥胖II级")
```

```
    .otherwise("肥胖III级(重度)")
)

# 计算各 BMI 类别的糖尿病患病率
bmi_risk = df_with_bmi_cat.groupBy("BMI_category") \
    .agg(
        count("*").alias("total_count"),
        count(when(col("Diabetes_012") == 2, 1)).alias("
           diabetic_count")
    ) \
    .withColumn("diabetic_rate", round(col("diabetic_count") / col("
       total_count") * 100, 2))
bmi_risk.orderBy("diabetic_rate").show()
```

分析结果：

表 7: BMI 分层糖尿病患病率及风险倍数

BMI 类别	BMI 范围	样本数	糖尿病患者数	患病率	风险倍数
偏瘦	< 18.5	3,127	169	5.40%	0.95
正常	18.5–25	68,953	3,928	5.70%	1.00
超重	25–30	93,749	10,692	11.40%	2.00
肥胖 I 级	30–35	53,451	10,281	19.23%	3.37
肥胖 II 级	35–40	20,663	5,669	27.44%	4.81
肥胖 III 级 (重度)	> 40	13,737	4,607	33.54%	5.88

从数据和图表可以清晰看到，随着 BMI 从正常范围向重度肥胖递进，糖尿病患病率呈单调递增趋势，呈现典型的**剂量-反应关系**。

1.4.3 结论三：体力活动的保护效应

规律的体力活动与较低的糖尿病风险显著相关。在非糖尿病人群中，保持体力活动的人群高血压风险降低 12.06 个百分点，高胆固醇风险降低 6.78 个百分点，BMI 平均降低 1.82。

分析代码：

$\texttt{protective}_{e}ffect = df.filter(col("Diabetes_{0}12") == 0)\ \ .groupBy("PhysActivity")\ \ .agg(count("*$
$").alias("sample_{c}ount"), round(mean("HighBP")*100, 2).alias("HighBP_{p}ct"), round(mean("HighC$

$100, 2).alias("HighChol_pct"), round(mean("BMI"), 2).alias("BMI_mean"), round(mean("Age"), 2).al$

分析结果：

表 8: 体力活动对不同糖尿病类别的影响

类别	体力活动	样本数	高血压比例	高胆固醇比例	BMI	年龄
2* 无糖尿病	有	166,491	34.45%	36.42%	27.34	7.66
	无	47,212	46.51%	43.20%	29.16	8.24
2* 糖尿病前期	有	3,142	60.73%	61.39%	30.08	9.06
	无	1,489	67.49%	63.53%	32.08	9.13
2* 糖尿病	有	22,287	73.23%	65.66%	31.17	9.30
	无	13,059	78.75%	69.32%	33.26	9.51

1.4.4 风险因素综合排序

表 9: 糖尿病风险因素综合排序（糖尿病组 vs 非糖尿病组）

排名	风险因素	非糖尿病组	糖尿病组	绝对差异	相对增长
1	高血压比例	37.11%	75.27%	**+38.15 p.p.**	+102.8%
2	高胆固醇比例	37.92%	67.01%	**+29.09 p.p.**	+76.7%
3	BMI 均值	27.74	31.94	**+4.20**	+15.1%
4	年龄均值	7.79	9.38	+1.59	+20.5%
5	体力活动比例	77.91%	63.05%	**-14.85 p.p.**	-19.1%

1.4.5 总结

基于以上三个观察结论，可以得出以下公共卫生启示：

1. **综合干预优先**：由于代谢指标存在聚集效应（高血压与高胆固醇共存比例在糖尿病组高达 54.36%），糖尿病预防应采取综合策略，同时关注血压、胆固醇和体重管理，而非单一指标干预。

2. **体重管理的核心地位**：BMI 与糖尿病风险存在明确的剂量-反应关系，重度肥胖人群的糖尿病风险是正常体重人群的 **5.88 倍**。体重控制应作为糖尿病一级预防的核心策略。

3. **生活方式干预的价值**：规律体力活动可使高血压风险降低约 12 个百分点，高胆固醇风险降低约 7 个百分点。体力活动不仅直接降低糖尿病风险，还通过改善血压和胆固醇水平间接产生保护效应，是成本效益最高的干预措施。

4. **风险因素排序**：按影响程度从大到小，与糖尿病最相关的风险因素依次为：**高血压 > 高胆固醇 > 高 BMI > 缺乏体力活动 > 高年龄**。其中前三个可干预的代谢因素贡献了最大的风险差异。

1.5 失败案例分析

1.5.1 失败案例记录

在使用 AutoClaw 过程中遇到一次连接失败问题，具体如下：

- **任务目标**：使用 AutoClaw 创建 Spark DataFrame，读取糖尿病数据集并执行描述性分析。
- **预期结果**：AutoClaw 成功执行代码，输出 DataFrame schema 和统计结果。
- **实际结果**：界面报错 `Error invoking remote method 'agent:send': Error: Not connected`，无法执行任何指令。
- **失败原因分析**：
  - 网络波动导致与后端服务器连接中断
  - 长时间闲置后连接自动断开，客户端未能自动重连
- **解决方案**：完全退出 AutoClaw 后重启，问题得到解决。

1.5.2 AutoClaw 最有价值之处

价值总结

自然语言驱动的大数据处理能力是 AutoClaw 最有价值的一方面。
用户无需熟练掌握 PySpark 语法，只需用自然语言描述分析需求（如“按糖尿病类别统计 BMI 均值”），AutoClaw 即可自动生成并执行 Spark 代码，并在出错时自动修正。这大幅降低了大数据分析的技术门槛，将“编码 → 调试”的循环从数小时缩短到几分钟。

2 生存分析报告：电信客户流失

2.1 摘要

本报告使用 Kaplan-Meier、Cox 比例风险模型和加速失效时间模型，对 IBM 电信客户流失数据进行生存分析。主要发现：客户中位生存时间为 34 个月，在线备份可将流失风险降低 54%。

2.2 数据准备

原始数据集包含 7,043 条客户记录，包含在网月数（tenure）和是否流失（churn）。经过筛选（月付合约 + 使用互联网服务），剩余 3,351 条记录，其中流失 1,556 人，删失（仍在网）1,795 人。

2.3 Kaplan-Meier 分析

2.3.1 总体结果

总观测数	3,351
流失事件数	1,556
删失数	1,795
中位生存时间	**34 个月**

解读：客户有 50% 的概率在网超过 34 个月。

2.3.2 Log-Rank 检验结果

变量	**p 值**	**是否显著**
性别	0.73	否
在线安全服务	<0.0001	**是**
在线备份	<0.0001	**是**
技术支持	<0.0001	**是**

解读：性别不影响客户流失；在线安全、在线备份、技术支持显著降低流失风险。

2.4 Cox 比例风险模型

2.4.1 模型结果

变量	系数	风险比 (HR)	p 值
有家属	-0.33	0.72	<0.005
DSL 宽带	-0.22	0.80	<0.005
在线备份	-0.78	**0.46**	<0.005
技术支持	-0.64	**0.53**	<0.005

解读:

- 在线备份：流失风险降低 54%（最强保护因素）
- 技术支持：流失风险降低 47%
- 有家属：流失风险降低 28%
- DSL 用户比光纤用户流失风险低 20%

2.4.2 比例风险假设检验

对 3 个变量的检验 p 值 < 0.005，违反比例风险假设。

2.5 加速失效时间模型 (AFT)

2.5.1 模型结果

变量	加速因子	解读
在线安全	2.37	在网时间延长 2.37 倍
在线备份	2.25	在网时间延长 2.25 倍
信用卡支付	2.22	在网时间延长 2.22 倍
有配偶	1.97	在网时间延长 1.97 倍

模型一致性指数为 0.73，优于 Cox 模型的 0.64。

2.6 客户生命周期价值 (CLV)

月份	12	24	36	48	60
累计 NPV（美元）	343.41	418.68	436.29	440.22	**441.00**

解读：默认客户画像的 60 个月 CLV 为 441 美元，大部分价值集中在前 24 个月。

2.7 结论

1. **KM 分析**：中位生存时间 34 个月；增值服务显著降低流失。
2. **Cox 模型**：在线备份（HR=0.46）和技术支持（HR=0.53）是最强保护因素。
3. **AFT 模型**：一致性更高（0.73），在线安全是最强保护因素。
4. **CLV 分析**：默认客户画像的 60 个月 CLV 为 441 美元。

3 第三问：LLM 生成 SQL 错误案例分析

3.1 数据库 Schema

本案例使用的数据库表结构如下（基于电信客户流失数据集）：

Listing 4: customers 表结构

```
CREATE TABLE customers (
    customerID VARCHAR(50) PRIMARY KEY,
    gender VARCHAR(10),
    SeniorCitizen INT,
    Partner VARCHAR(3),
    Dependents VARCHAR(3),
    tenure INT,
    PhoneService VARCHAR(3),
    MultipleLines VARCHAR(20),
    InternetService VARCHAR(20),
    OnlineSecurity VARCHAR(20),
    OnlineBackup VARCHAR(20),
    DeviceProtection VARCHAR(20),
    TechSupport VARCHAR(20),
    StreamingTV VARCHAR(20),
    StreamingMovies VARCHAR(20),
```

```
    Contract VARCHAR(20),
    PaperlessBilling VARCHAR(3),
    PaymentMethod VARCHAR(30),
    MonthlyCharges DECIMAL(10,2),
    TotalCharges DECIMAL(10,2),
    Churn VARCHAR(3)
);
```

3.2 案例一：NULL 值处理失败

3.2.1 用户问题

" 计算所有客户的平均 TotalCharges"

3.2.2 LLM 生成的错误 SQL

Listing 5: LLM 生成的错误 SQL

```
SELECT AVG(TotalCharges) FROM customers;
```

3.2.3 正确的 SQL

Listing 6: 正确的 SQL

```
SELECT AVG(CAST(NULLIF(TotalCharges, '') AS DECIMAL(10,2)))
FROM customers
WHERE TotalCharges IS NOT NULL AND TotalCharges != '';
```

3.2.4 失败原因分析

在原始 CSV 数据中，`TotalCharges` 列存在空字符串（新注册用户尚未产生费用）。LLM 默认假设数据是干净的，直接使用 `AVG(TotalCharges)` 会导致：

- 空字符串无法转换为 DECIMAL，查询报错
- 即使能运行，也会错误地统计了无效数据

真实数据中这种" 脏数据" 非常常见，但 LLM 缺乏" 数据质量检查" 的意识。

3.3 案例二：字段语义误解

3.3.1 用户问题

" 找出 SeniorCitizen 中，现在还在使用我们服务的客户"

3.3.2 LLM 生成的错误 SQL

Listing 7: LLM 生成的错误 SQL

```
SELECT * FROM customers WHERE SeniorCitizen = 1 AND Churn = 'No';
```

3.3.3 正确的 SQL

Listing 8: 正确的 SQL

```
-- 注意: SeniorCitizen = 1 表示是老年人
-- 但"现在还在使用服务"需要排除已流失的客户
SELECT customerID, SeniorCitizen, Churn
FROM customers
WHERE SeniorCitizen = 1 AND (Churn = 'No' OR Churn IS NULL);
```

3.3.4 失败原因分析

LLM 可能误解" 还在使用" 的含义:

- 如果 `Churn` 列有 NULL（例如新客户还没标记流失状态），直接过滤 `Churn = 'No'` 会漏掉 NULL 行
- LLM 没有考虑到 `Churn` 列的完整取值情况（'Yes' / 'No' / NULL / 空字符串）

这是一个**字段语义和完整性理解不足**的典型错误。

3.4 案例三：复杂嵌套查询的条件作用域错误

3.4.1 用户问题

" 找出月费（MonthlyCharges）高于使用光纤互联网且未流失的客户的平均月费的那些月付合约客户"

3.4.2 LLM 生成的错误 SQL

Listing 9: LLM 生成的错误 SQL

```
SELECT * FROM customers
WHERE MonthlyCharges > (
    SELECT AVG(MonthlyCharges)
    FROM customers
    WHERE InternetService = 'Fiber␣optic' AND Churn = 'No'
```

```
)
AND Contract = 'Month-to-month';
```

3.4.3 正确的 SQL

Listing 10: 正确的 SQL

```
SELECT * FROM customers
WHERE Contract = 'Month-to-month'
  AND MonthlyCharges > (
      SELECT AVG(MonthlyCharges)
      FROM customers
      WHERE InternetService = 'Fiber␣optic'
        AND Churn = 'No'
        AND Contract = 'Month-to-month'
  );
```

3.4.4 失败原因分析

LLM 的错误在于**条件作用域不一致**：

- 父查询只筛选 `Contract = 'Month-to-month'`
- 子查询计算的是**所有**光纤互联网未流失用户的平均月费（包括长合约用户）
- 这导致对比基准不公平：拿月付合约用户与全量用户比较

正确做法是子查询也应限定为月付合约用户，保证比较的群体一致。这种**逻辑嵌套错误**是 LLM 在复杂查询中的常见弱点。

3.5 LLM 在 SQL 生成中可能失败的根本原因总结

表 10: LLM 失败原因总结

失败类型	**说明**
数据质量假设	默认数据是干净的，忽略 NULL、空字符串、缺失值
字段语义理解不足	不理解字段的业务含义和完整取值
条件作用域错位	复杂嵌套查询中 WHERE 条件的作用范围混淆
JOIN 过度泛化	脑补不存在的关联表
方言差异	不同数据库语法不同（如 LIMIT vs TOP）
性能意识缺失	生成全表扫描 SQL，在大数据场景不可行

4 第四问：个人网站与博客部署

4.1 完成步骤

4.1.1 创建 GitHub Pages 网站

首先，创建一个符合 GitHub Pages 命名规范的仓库：用户名`.github.io`。本项目的用户名为 `turtledove1111`，因此仓库名称为：

```
turtledove1111.github.io
```

将仓库设置为公开（Public），并添加 `README.md` 作为首页内容。

4.1.2 发布生存分析报告

将第二问生成的生存分析报告（PDF 格式）上传至仓库根目录，文件名为 `report.pdf`。同时，编辑 `README.md`，使其成为一篇包含报告摘要和下载链接的博客文章。

4.1.3 验证网站可访问性

部署完成后，通过浏览器访问以下地址验证：

```
https://turtledove1111.github.io
```

网站正常显示首页内容，并可成功下载 PDF 报告。

4.2 成果展示

4.2.1 网站首页截图

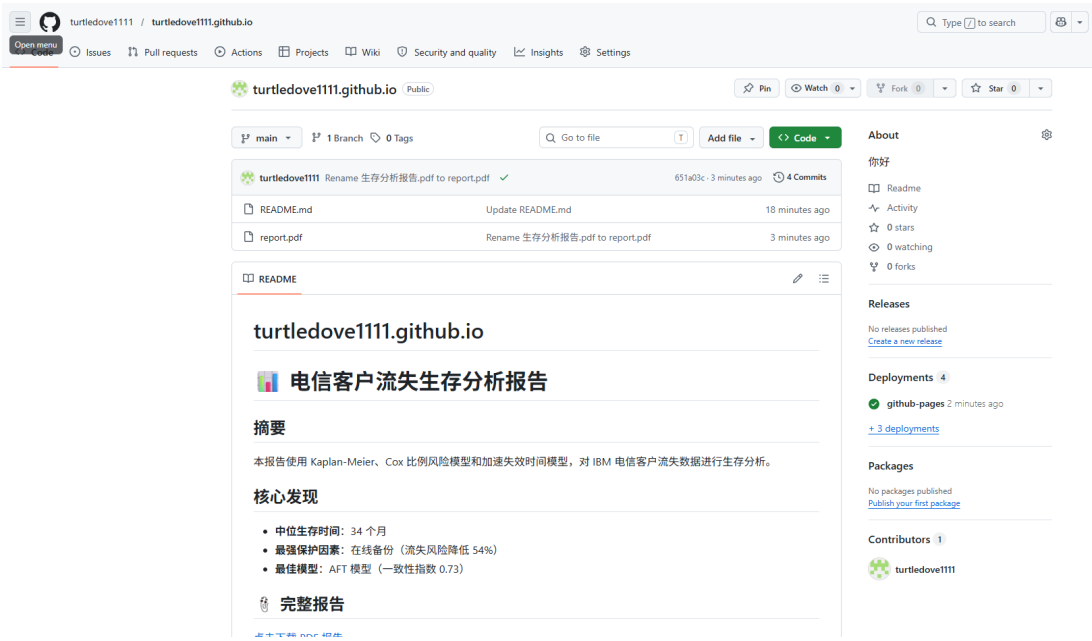

图 1: GitHub Pages 网站首页截图

4.3 访问信息

- **网站地址**：https://turtledove1111.github.io
- **报告直接链接**：https://turtledove1111.github.io/report.pdf